

Statistiques

I Ajustement linéaire par la méthode de Mayer

On a recueilli les données concernant les notes x de mathématiques et y de physique d'un certain nombre d'élèves de la classe. Les données sont présentées dans un tableau :

x	10	12	10	13	09	11	12	11	13	12	14	10	15	10	12
y	11	13	10	13	10	10	12	12	14	13	15	10	16	11	13

1 Situation problème

Peut-on prédire la note y de physique d'un élève qui a obtenu une note x en mathématiques ? En d'autres termes, peut-on trouver a et b réels tels que

$$y = ax + b ?$$

2 Activité d'apprentissage

Série marginale en x

x_i	09	10	11	12	13	14	15	Total
n_i								15

La moyenne $\bar{x}$ en mathématiques est $\bar{x} = \dots\dots\dots = \dots\dots\dots$

Série marginale en y

y_i	10	11	12	13	14	15	16	Total
n_i								15

La moyenne $\bar{y}$ en physique est $\bar{y} = \dots\dots\dots = \dots\dots\dots$

Coordonnées du point moyen G

Le point moyen est $G(\bar{x}; \bar{y})$, donc $G(\dots\dots\dots; \dots\dots\dots)$.

Nuage de points

C'est la représentation des points $(x_i; y_i)$ du tableau à double entrée des données.

Représenter les points.

Ces points semblent être regroupés autour d'une droite affine ; donc l'ajustement linéaire de y en x est possible. En posant $(\Delta) : y = ax + b$ cette droite, le but est de rechercher a et b .

Détermination de la droite d'ajustement linéaire de y en x par la méthode de Mayer

Divisons la série statistique en deux sous-séries de même effectif ou d'effectifs différents de 1 (ici 8 et 7).

x_i	10	12	10	13	09	11	12	11
y_i	11	13	10	13	10	10	12	12

x_i	13	12	14	10	15	10	12
y_i	14	13	15	10	16	11	13

Pour chaque sous-série, calculons les points moyens G_1 et G_2 :

$$\begin{aligned} G_1(\bar{x}_1; \bar{y}_1) & \text{ donc } G_1(\dots\dots\dots; \dots\dots\dots) \\ G_2(\bar{x}_2; \bar{y}_2) & \text{ donc } G_2(\dots\dots\dots; \dots\dots\dots). \end{aligned}$$

i) Calculer $a = \frac{\bar{y}_1 - \bar{y}_2}{\bar{x}_1 - \bar{x}_2} = \dots\dots\dots = \dots\dots\dots$

ii) Calculer $b = \bar{y}_1 - a\bar{x}_1$ ou $b = \bar{y}_2 - a\bar{x}_2$ ou $b = \bar{y} - a\bar{x}$.

iii) L'équation de la droite d'ajustement linéaire par la méthode de Mayer est $y = ax + b$.

Remarque : c'est en fait la droite (G_1G_2) ; elle passe toujours par le point $G(\bar{x}; \bar{y})$.

3 Retenons

- Lorsque le nuage de points a la « forme » d'une droite, on peut faire un ajustement linéaire de y en x .
- La méthode de Mayer consiste à diviser la série statistique en deux sous-séries, à déterminer les coordonnées des deux points moyens G_1 et G_2 , puis à déterminer l'équation de la droite (G_1G_2) : $y = ax + b$ où

$$a = \frac{\bar{y}_1 - \bar{y}_2}{\bar{x}_1 - \bar{x}_2} \quad \text{et} \quad b = \bar{y}_1 - a\bar{x}_1.$$

4 Exercice d'application

- Pour l'activité d'apprentissage, l'équation de la droite d'ajustement linéaire est $y = ax + b = \dots\dots\dots$
- Déterminer la note théorique de physique d'un élève qui a obtenu 17 en mathématiques.
- Déterminer la note théorique de mathématiques d'une élève qui a obtenu 8 en physique.
- Vérifier que G appartient à cette droite.

II Ajustement linéaire par la méthode des moindres carrés

À partir du tableau des données :

x_i	10	12	10	13	09	11	12	11	13	12	14	10	15	10	12
y_i	11	13	10	13	10	10	12	12	14	13	15	10	16	11	13

1 Activité d'apprentissage

- Calculer la moyenne

$$\bar{x} = \frac{\sum_{i=1}^{15} x_i}{N} = \frac{\dots\dots\dots}{15} = \dots\dots\dots$$

et la moyenne

$$\bar{y} = \frac{\sum_{i=1}^{15} y_i}{N} = \frac{\dots\dots\dots}{15} = \dots\dots\dots ;$$

c'est la méthode directe lorsqu'on a un tableau à deux lignes ; mais on peut aussi utiliser les séries marginales en X et en Y .

- Calculer la covariance de (X, Y) en complétant le tableau et en appliquant les formules.

																Total
x_i	10	12	10	13	09	11	12	11	13	12	14	10	15	10	12	—
y_i	11	13	10	13	10	10	12	12	14	13	15	10	16	11	13	—
$x_i \times y_i$																

- La covariance de (X, Y) est

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^{15} x_i y_i}{N} - \bar{x} \bar{y} = \frac{\dots\dots\dots}{15} - (\dots\dots\dots)(\dots\dots\dots) = \dots\dots\dots$$

- Calcul de la variance de X , $V(X)$; de l'écart type de X , σ_X ; de la variance de Y , $V(Y)$; de l'écart type de Y , σ_Y .

Ici, on utilise la série marginale en X et la série marginale en Y .

x_i	09	10	11	12	13	14	15	Total
n_i	1	4	2	4	2	1	1	15
$n_i \times x_i$								
x_i^2								—
$n_i \times x_i^2$								

y_i	10	11	12	13	14	15	16	Total
n_i	4	2	2	4	1	1	1	15
$n_i \times y_i$								
y_i^2								—
$n_i \times y_i^2$								

On a alors :

La moyenne de X est

$$\bar{x} = \frac{\sum_{i=1}^7 n_i x_i}{N} = \frac{\dots\dots\dots}{15} = \dots\dots\dots$$

La moyenne de Y est

$$\bar{y} = \frac{\sum_{i=1}^7 n_i y_i}{N} = \frac{\dots\dots\dots}{15} = \dots\dots\dots$$

La variance de X est

$$V(X) = \frac{\sum_{i=1}^7 n_i x_i^2}{N} - (\bar{x})^2 = \dots\dots\dots$$

La variance de Y est

$$V(Y) = \frac{\sum_{i=1}^7 n_i y_i^2}{N} - (\bar{y})^2 = \dots\dots\dots$$

L'écart type de X est

$$\sigma_X = \sqrt{V(X)} = \dots\dots\dots = \dots\dots\dots$$

L'écart type de Y est

$$\sigma_Y = \sqrt{V(Y)} = \dots\dots\dots = \dots\dots\dots$$

Exercice. Avec les données précédentes, calculer

$$a = \frac{\text{cov}(X, Y)}{V(X)} = \dots\dots\dots ; \quad a' = \frac{\text{cov}(X, Y)}{V(Y)} = \dots\dots\dots$$

- Déterminer le point moyen $G(\bar{x}; \bar{y}) : G(\dots\dots\dots ; \dots\dots\dots)$.
- Calculer $a \times a' = \dots\dots\dots = \dots\dots\dots$.
- Calculer $r = \frac{\text{cov}(X, Y)}{\sqrt{V(X)} \times \sqrt{V(Y)}}$.

2 Corrélation linéaire entre X et Y

Retenons.

- Le coefficient de corrélation linéaire entre X et Y est

$$r = \frac{\text{cov}(X, Y)}{\sqrt{V(X)} \times \sqrt{V(Y)}}.$$

- Si $|r| \leq 0,5$, on dit que la corrélation est faible.
Si $0,7 \leq |r| < 1$, on dit que la corrélation est bonne ou forte.
Si $|r| = 1$, on dit que la corrélation est parfaite.
- L'ajustement linéaire se justifie si $0,7 \leq |r| \leq 1$.

3 Droite de régression de y en x ou droite d'ajustement linéaire obtenue par la méthode des moindres carrés

On calcule

$$a = \frac{\text{cov}(X, Y)}{V(X)} \quad \text{et} \quad G(\bar{x}; \bar{y}),$$

alors

$$(\Delta) : y - \bar{y} = a(x - \bar{x});$$

on en déduit $y = ax + \bar{y} - a\bar{x}$, ou bien

$$y = ax + b \quad \text{avec} \quad a = \frac{\text{cov}(X, Y)}{V(X)} \quad \text{et} \quad b = \bar{y} - a\bar{x}.$$

Remarque : pour la droite de régression de x en y , on calcule

$$a' = \frac{\text{cov}(X, Y)}{V(Y)}$$

et

$$(\Delta') : x - \bar{x} = a'(y - \bar{y}), \quad \text{c'est-à-dire} \quad x = a'y + \bar{x} - a'\bar{y}.$$

Attention :

- le coefficient directeur de (Δ') est $\frac{1}{a'} = \frac{V(Y)}{\text{cov}(X, Y)}$;
- on a : $a \times a' = \frac{(\text{cov}(X, Y))^2}{V(X) V(Y)} = r^2$;
- justifier que a , a' et $\text{cov}(X, Y)$ ont le même signe.

4 Exercice d'application

- a) Ayant calculé le coefficient de corrélation linéaire de l'activité d'apprentissage, qualifier la corrélation entre X et Y .
- Écrire l'équation de la droite de régression de y en x .
 - Un élève a 16 en mathématiques ; estimer sa note théorique de physique.
 - Une élève a 8 en physique ; estimer sa note théorique de mathématiques.
- b) $(\Delta_1) : y = 6x - 38$ et $(\Delta_2) : x = 0,135y + 6,65$ sont les droites de régression d'une série double. Déterminer G et r . Que dire de la corrélation de X et Y ?
- Même exercice pour $(\Delta_1) : y = 0,8x - 3$ et $(\Delta_2) : x = 0,9y + 5,5$.
 - Même exercice pour $(\Delta_1) : y = 1,5x + 3$ et $(\Delta_2) : x = 0,54y - 0,86$.
- c) La droite de régression de y en x d'équation $y = \frac{27}{14}x + \frac{16}{7}$ a été obtenue à partir du tableau ci-dessous ; les réels a et b ont été malheureusement effacés. Déterminer les nombres a et b .

x_i	1	2	3	4	5	6	7
y_i	4	6	a	10	13	b	15

- d) On considère le tableau suivant :

x_i	1	2	3	4	5	6	7
y_i	a	$a + 2$	$2a$	$b - 4$	$b - 1$	b	$b + 1$

La droite de régression de y en x a pour équation $27x - 14y + 32 = 0$.

- Calculer a et b .
 - Restituer le tableau original.
- e) On considère le tableau suivant :

x_i	5	10	11	8	7	6	9
y_i	11	21	23	17	15	13	19

- La corrélation entre x et y est-elle parfaite ?
- Écrire l'équation de la droite de régression de y en x .