

STATISTIQUES

I Ajustement linéaire par la méthode de MAYER

On a recueilli les données concernant les notes x de mathématiques et y de physique d'un certain nombre d'élèves de la classe. Les données sont présentées dans un tableau.

X	10	12	10	13	09	11	12	11	13	12	14	10	15	10	12		
Y	11	13	10	13	10	10	12	12	14	13	15	10	16	11	13		

1) situation problème: Peut-on prédire la note y de physique d'un élève qui a obtenu une note x en mathématiques?
En d'autres termes, peut-on trouver a et b réels tels que $y = ax + b$?

2) Activité d'apprentissage:

• série marginale en x

x_i	09	10	11	12	13	14	15	Total
n_i								15

la moyenne $\bar{x}$ en maths
est $\bar{x} = \quad =$

• série marginale en y

y_i	10	11	12	13	14	15	16	Total
n_i								15

la moyenne $\bar{y}$ en physique
est $\bar{y} = \quad =$

• Coordonnées du point moyen G

le point moyen est $G(\bar{x}, \bar{y})$ donc $G(\dots; \dots)$

• Nuage de points

C'est la représentation des points $(x_i; y_i)$ du tableau à double entrée des données.
Représenter les points.

Les points semblent se regrouper autour d'une droite affine; donc l'ajustement linéaire de y en x est possible.

En posant (A): $y = ax + b$ cette droite, le but est de rechercher a et b .

• Détermination de la droite d'ajustement linéaire de y en x par la méthode de MAYER.

Divisons la série statistique en deux sous-séries de même effectif ou de effectifs différents de 1 (ici 8 et 7)

x_i	10	12	10	13	09	11	12	11
y_i	11	13	10	13	10	10	12	12

x_i	13	12	14	10	15	10	12
y_i	14	13	15	10	16	11	13

Pour chaque sous-série calculons les points moyens

G_1 et G_2

$G_1(\bar{x}_1; \bar{y}_1)$ donc $G_1(1; 1)$

$G_2(\bar{x}_2; \bar{y}_2)$ donc $G_2(1; 1)$

1) calculer $a = \frac{\bar{y}_1 - \bar{y}_2}{\bar{x}_1 - \bar{x}_2} = \dots$

2) calculer $b = \bar{y}_1 - a\bar{x}_1$ ou $b = \bar{y}_2 - a\bar{x}_2$ ou $b = \bar{y} - a\bar{x}$

3) l'équation de la droite d'ajustement linéaire par la méthode de HAYER est $y = ax + b$
Et c'est en fait la droite (G_1, G_2) elle passe toujours par le point $G(\bar{x}, \bar{y})$

3) Retenons

- Lorsque le nuage de points a la "forme" d'une droite, On peut faire un ajustement linéaire de y en x .

- la méthode de HAYER consiste à diviser la série statistique en deux sous séries et à déterminer les coordonnées des deux points moyens G_1 et G_2 et à déterminer l'équation de la droite $(G_1, G_2) : y = ax + b$

où $a = \frac{\bar{y}_1 - \bar{y}_2}{\bar{x}_1 - \bar{x}_2}$ et $b = \bar{y}_1 - a\bar{x}_1$

4) Exercice d'application

- Pour l'activité d'apprentissage l'équation de la droite d'ajustement linéaire est $y = ax + b = \dots$

- Déterminer la note théorique de physique d'un élève qui a obtenu 17 en maths.

- Déterminer la note théorique de mathématique d'un élève qui a obtenu 8 en physique.

- Vérifier que G appartient à cette droite.

II. Ajustement linéaire par la méthode des moindres carrés

A partir du tableau des données

x_i	10	12	10	13	09	11	12	11	13	12	14	10	15	10	12
y_i	11	13	10	13	10	10	12	12	14	13	15	10	16	11	13

1) Activité d'apprentissage

- calculer la moyenne $\bar{x} = \frac{\sum_{i=1}^{15} x_i}{N} = \frac{\dots}{15} =$
et la moyenne $\bar{y} = \frac{\sum_{i=1}^{15} y_i}{N} = \frac{\dots}{15} =$;

c'est la méthode directe lorsque on a un tableau à deux lignes; mais on peut aussi utiliser les séries marginales en x et en y .

- calculer la covariance de (x, y) en complétant le tableau et en appliquant les formules

x_i	10	12	10	13	09	11	12	11	13	12	14	10	15	10	12	12
y_i	11	13	10	13	10	10	12	12	14	13	15	10	16	11	13	13
$x_i y_i$																T_0

- la covariance de (x, y) est

$$COV(x, y) = \frac{\sum_{i=1}^{15} x_i y_i}{N} - \bar{x} \bar{y} = \dots - ()$$

= ...

- Calcul de la variance de x , $V(x)$; de l'écart type de x , σ_x ; variance de y , $V(y)$; l'écart type de y , σ_y .
ici, on utilise la série marginale en x et la série marginale en y

x_i	09	10	11	12	13	14	15	Total	y_i	10	11	12	13	14	15	16
n_i	1	4	2	4	2	1	1	15	n_i	4	2	2	4	1	1	1
$n_i \times x_i$									$n_i y_i$							
x_i^2									y_i^2							
$n_i \times x_i^2$									$n_i y_i^2$							

On a alors

la moyenne de x est

$$\bar{x} = \frac{\sum_{i=1}^n n_i x_i}{N} = \frac{\dots}{15} =$$

la variance de x est

$$V(x) = \frac{\sum_{i=1}^n n_i x_i^2}{N} - (\bar{x})^2$$

=

l'écart type de x est

$$\sigma_x = \sqrt{V(x)}$$

=

=

la moyenne de y est

$$\bar{y} = \frac{\sum_{i=1}^n n_i y_i}{N} = \frac{\dots}{15} =$$

la variance de y est

$$V(y) = \frac{\sum_{i=1}^n n_i y_i^2}{N} - (\bar{y})^2$$

=

l'écart type de y est

$$\sigma_y = \sqrt{V(y)}$$

=

=

Exercice. Avec les données précédentes,
calculer

$$a = \frac{\text{Cov}(x, y)}{V(x)} ; d = \frac{\text{Cov}(x, y)}{V(y)}$$

=

=

déterminer le point moyen $G(\bar{x}, \bar{y})$
 $G(\quad , \quad)$.

• calculer $a \times a'$ =

• calculer $r = \frac{\text{Cov}(x, y)}{\sqrt{V(x)} \times \sqrt{V(y)}}$

2) • Corrélation linéaire entre x et y

Rétenons

• le coefficient de corrélation linéaire entre x et y est $r = \frac{\text{cov}(x,y)}{\sqrt{v(x)} \cdot \sqrt{v(y)}}$

• si $|r| \leq 0,5$ on dit que la corrélation est faible.

• si $0,7 \leq |r| < 1$ on dit que la corrélation est bonne ou forte.

• si $|r| = 1$ on dit que la corrélation est parfaite.

• l'ajustement linéaire se justifie si $0,7 \leq |r| \leq 1$

3) • Droite de régression de y en x ou droite d'ajustement linéaire obtenue par la méthode des moindres carrés

On calcule $a = \frac{\text{cov}(x,y)}{v(x)}$; et $G(\bar{x}; \bar{y})$

alors (D): $y - \bar{y} = a(x - \bar{x})$; et on déduit

$y = ax + \bar{y} - a\bar{x}$, ou bien $\begin{cases} y = ax + b \\ a = \frac{\text{cov}(x,y)}{v(x)} \text{ et } b = \bar{y} - a\bar{x} \end{cases}$

Et Pour la droite de régression de x en y

On calcule $a' = \frac{\text{cov}(x,y)}{v(y)}$

et (D'): $x - \bar{x} = a'(y - \bar{y})$ i.e. $x = a'y + \bar{x} - a'\bar{y}$.

Attention: le coefficient directeur de (D') est $\frac{1}{a'} = \frac{v(x)}{\text{cov}(x,y)}$

on a: $aa' = \frac{(\text{cov}(x,y))^2}{v(x)v(y)} = r^2$.

• Justifier que a , a' et $\text{cov}(x,y)$ ont le même signe.

4) • Exercice et application

a) Ayant calculé le coefficient de corrélation linéaire de l'activité d'apprentissage, qualifier la corrélation entre x et y.

b) Écrire l'équation de la droite de régression de y en x.

c) Un élève a 16 en MATH, estimer sa note théorique de physiques.

d) Une élève a 8 en Physiques, estimer sa note théorique de Mathématiques.

e) (D₁): $y = 6x - 38$ et (D₂): $x = 0,135y + 6,65$ sont les droites de régression d'une série double. Déterminer G et r que dire de la corrélation de x et y.

• à retenir pour (D₁): $y = 0,8x - 3$ et (D₂): $x = 0,9y + 5,5$

• même exercice pour (Δ_1): $y = 1,5x + 3$ et
 (Δ_2): $x = 0,54y - 0,86$.

c) la droite de régression de y en x d'équation
 $y = \frac{27}{14}x + \frac{16}{7}$ a été obtenue à partir
 du tableau ci-dessous: les reals a et b ont été
 malheureusement effacés, déterminer les nombres a et
 b .

x_i	1	2	3	4	5	6	7
y_i	4	6	a	10	13	b	15

d)

x_i	1	2	3	4	5	6	7
y_i	a	$a+2$	$2a$	$b-4$	$b-1$	b	$b+1$

la droite de régression de y en x est pour
 l'équation $27x - 14y + 32 = 0$

i) Calculer a et b .

ii) Reconstituer le tableau original.

e)

x_i	5	10	11	8	7	6	9
y_i	11	21	23	17	15	13	19

i) La corrélation entre x et y est-elle parfaite?
 ii) Écrire l'équation de la droite de régression de y
 en x .